

Questions TP1

Partie 1 :

1-Commande d'installation : `pip install nom_de_bibliothèque`

2-Différence entre NLTK et spaCy :

- **NLTK** : C'est une bibliothèque académique. Elle propose de nombreux algorithmes configurables, ce qui la rend idéale pour l'apprentissage, l'expérimentation et la recherche.
- **spaCy** : C'est une bibliothèque professionnelle conçue pour la production. Elle est très rapide et applique directement un pipeline complet et optimisé sur le texte.

Partie 2 :

1-Pour éviter que le modèle ne traite "Bonjour", "BONJOUR" et "bonjour" comme 3 mots différents. Cela permet d'uniformiser le vocabulaire et de réduire la taille du dictionnaire.

2-Exemple avant et après nettoyage :

- **Avant**: "Bonjour ! Le NLP est VRAIMENT passionnant en 2026, n'est-ce pas ?"
- **Après**: "bonjour le traitement automatique du langage naturel
nlp est vraiment passionnant en 2026 nestce pas"

Partie 3 :

1-

Ce sont des mots vides ou très fréquents dans la langue comme les articles, prépositions et pronoms : *le, la, de, et, du, est*. Ils n'apportent pas de valeur sémantique (de sens) propre à l'analyse du texte.

2-

On calcule cette proportion en divisant le nombre de stopwords supprimés par le nombre total de tokens initiaux, puis en multipliant par 100 :

$$Proportion = \frac{\text{Nombre de tokens supprimés}}{\text{Nombre Total De Tokens Initial}} \times 100$$

Partie 4 :

1-

Stemming : Il coupe la fin des mots de façon mécanique pour ne garder que la racine (ex. : *passionnant* → *passionn*). C'est une méthode rapide, mais elle produit parfois des mots qui n'existent pas dans le dictionnaire.

Lemmatisation : Elle utilise un dictionnaire et des règles grammaticales pour ramener chaque mot à sa forme de base (ex. : un verbe conjugué à l'infinitif, un adjectif au masculin singulier). Elle produit toujours des mots réels et corrects.

2-

Parce qu'elle regroupe toutes les variations d'un même mot (conjugaisons, pluriels...) sous un seul concept de base. Cela réduit le nombre de mots différents à traiter et permet au modèle de mieux comprendre le sens global sans se disperser.